

1- Análise de regressão logística binária (Passos)

- ① Desenhar um gráfico de dispersão para as variáveis preditoras e a variável resposta para ver se parece haver relação entre elas
- ② Encontrar a equação de regressão logística
- ③ Avaliar a acurácia da equação
- ④ Realizar um teste de hipóteses
- ⑤ Realizar uma previsão


2.0 modelo logístico

A forma da equação da regressão logística é :

$$y = \frac{1}{1 + e^{-(a_1x_1 + a_2x_2 + \dots + a_px_p + b)}}$$

Diagrama explicativo da equação:

- $x_1, x_2, \dots, x_p$: variáveis preditoras (x)
- $a_1, a_2, \dots, a_p$: coeficientes de regressão
- b : intercepto



• Não importa o valor de z o valor de y nunca será maior que 1 ou menor que 0.

3- Máxima Verossimilhança



É usada para estimar os valores os valores dos parâmetros de uma população utilizando uma amostra representativa. As estimativas são baseadas em probabilidade.

Exemplo: Imagine que foi questionado sobre quem gosta de beber café.

Pessoas	Você gosta de beber café?
1	Sim
2	Não
3	Sim
4	Não
5	Sim
6	Sim
7	Sim
8	Sim
9	Não
10	Sim

parâmetro para identificar quem gosta ou não de café: p

$$p \times (1-p) \times p \times (1-p) \times p \times p \times p \times (1-p) \times p = p^7 \cdot (1-p)^3 \text{ ou } \log \{ p^7 \cdot (1-p)^3 \}$$



Encontrando a máxima Verossimilhança

$$p^7 \cdot (1-p)^3 \quad (\text{Exemplo})$$

$$L = \log(p^7 \cdot (1-p)^3)$$

$$L = \log p^7 + \log(1-p)^3$$

$$L = 7 \cdot \log p + 3 \log(1-p)$$

Derivando L em relação a p e igualando a 0, pois será necessário encontrar o ponto crítico (que é o ponto máximo).

$$\frac{dL}{dp} = 7 \cdot \frac{1}{p} + 3 \cdot \frac{1}{1-p} \cdot (-1) = \frac{7}{p} - \frac{3}{1-p} = 0 \quad \therefore p = \frac{7}{10} = 0,7$$

4. Determinando a equação logística binomial para cada amostra

Variável 1	Variável 2	Variável Resp	$\hat{y}$
0	28	1	$\frac{1}{1 + e^{-(a_1 \cdot 0 + a_2 \cdot 28 + b)}}$
0	24	0	$\frac{1}{1 + e^{-(a_1 \cdot 0 + a_2 \cdot 24 + b)}}$
⋮	⋮	⋮	⋮
1	24	0	$\frac{1}{1 + e^{-(a_1 \cdot 1 + a_2 \cdot 24 + b)}}$

Obtendo a função de Verossimilhança. Quando a variável resposta for 1 é sucesso e 0 é não sucesso ou seja:

$$\underbrace{\frac{1}{1 + e^{-(a_1 \cdot 0 + a_2 \cdot 28 + b)}}}_{\text{sucesso}} \cdot \underbrace{\left(1 - \frac{1}{1 + e^{-(a_1 \cdot 0 + a_2 \cdot 24 + b)}}\right)}_{\text{não sucesso}} \cdot \dots \cdot \underbrace{\frac{1}{1 + e^{-(a_1 \cdot 1 + a_2 \cdot 24 + b)}}}_{\text{sucesso}}$$

$$L = \log_e \left(\frac{1}{1 + e^{-(a_1 \cdot 0 + a_2 \cdot 28 + b)}} \right) + \log_e \left(1 - \frac{1}{1 + e^{-(a_1 \cdot 0 + a_2 \cdot 24 + b)}} \right) + \dots + \log_e \left(\frac{1}{1 + e^{-(a_1 \cdot 1 + a_2 \cdot 24 + b)}} \right)$$

Através de pacotes no R ou Python que calcula os coeficientes...

$$a_1 = 2.44$$

$$a_2 = 0.54$$

$$b = -15.20$$

$$L = -8.9 \quad \text{e} \quad y = \frac{1}{1 + e^{-(2.44x_1 + 0.54x_2 - 15.20)}}$$

5. Avaliando a acurácia da equação

Na regressão logística binária calcula-se o pseudo- R^2 .

Um dos métodos mais usados é o de McFadden's.

$$R^2 = - \frac{\text{Máximo valor da função de log-verossimilhança } L}{N_1 \cdot \log N_1 + N_0 \log N_0 - (N_1 + N_0) \log (N_1 + N_0)}$$

N_1 = Número de pontos cuja variável é 1 (sucesso)


N_0 = Número de pontos cuja variável é 0 (não sucesso)

Se o pseudo- R^2 for baixo é preciso lembrar que na regressão logística os valores não baixos mesmo e que um valor próximo de 0.4 atende como um bom resultado.

6 - Taxa de erro aparente

$$\frac{\text{número total de amostras que não ficaram com a previsão}}{\text{número total de amostras}}$$

Aconselha-se fazer um gráfico de ~~dispersão~~ dispersão

$y = \hat{y}$:  e verificar o coeficiente de correlação.

7 - Testes de hipóteses

1 - Testes de hipóteses abrangentes

Hipótese nula: $\alpha_1 = \alpha_2 = 0$

Hipótese alternativa: $\alpha_1 \neq 0$ e $\alpha_2 \neq 0$

$\alpha_1 \neq 0$ e $\alpha_2 = 0$

$\alpha_1 = 0$ e $\alpha_2 \neq 0$

2 - Teste de hipóteses para um coeficiente de regressão individual

Hipótese nula: $\alpha_i = 0$

Hipótese alternativa: $\alpha_i \neq 0$

Teste da razão de verossimilhanças (examinar todos os coeficientes)

- ① Definir a população
- ② Definir a hipótese nula e a alternativa
- ③ Escolher qual teste de hipótese conduzir (teste de razão de verossimilhança)
- ④ Escolher o nível de significância (usar 0.05)
- ⑤ Calcular a estatística de teste: $2(L - n_1 \log_e(n_1) - n_0 \log_e(n_0) + (n_1 + n_0) \log_e(n_1 + n_0))$
- ⑥ Determinar o valor-p para a estatística de teste
- ⑦ se $\text{valor-p} < 0.05$ rejeitar a hipótese nula, mas se for $\text{valor-p} \geq 0.05$ aceitar a hipótese nula

Teste de Wald (Para verificar se cada uma das variáveis preditoras possuem efeito significativo).

- ① Definir a população
- ② Definir uma hipótese nula ($\alpha_i = 0$) e alternativa ($\alpha_i \neq 0$)
- ③ Escolher um teste (teste de Wald)
- ④ Escolher o nível de significância (usar 0.05)
- ⑤ Calcular a estatística de teste (teste de Wald):
$$\frac{\alpha_i^2}{S_{ii}}$$
- ⑥ Determinar o valor-p na estatística obtida
- ⑦ se $\text{valor-p} < 0.05$ rejeitar a hipótese nula, mas se $\text{valor-p} \geq 0.05$ aceitar a hipótese nula.

8- Realizar uma previsão com o modelo

Com o modelo validado já se pode realizar previsão